การควบคุมเหมาะที่สุดแบบสโทแคสติก (Stochastic Optimal Control)

01208583 Robotics

Varodom Toochinda, Ph.D
Dept. of Mechanical Engineering
Kasetsart University

Outline

- ปัญหาการควบคุมแบบสโทแคสติก
- ตัวควบคุมกำลังสองเชิงเส้นแบบเกาส์เซียน (LQG)
- การประมาณค่าสถานะเหมาะที่สุด
- ตัวกรองคาลมาน
  - ขั้นการทำนาย
  - ขั้นการปรับค่าวัด
  - อัลกอริทึม KF

8 การควบคุมเหมาะที่สุดแบบสโทแคสติก

จากการศึกษาในบทที่ผ่านมา เราตั้งสมมุติฐานว่าทุกสิ่งทุกอย่างบนโลกนี้เป็นแบบเชิงกำหนด ทำให้สามารถพยากรณ์ค่าในอนาคตได้อย่างแม่นยำ ซึ่งในความเป็นจริงไม่เป็นเช่นนั้น ค่าที่วัดได้จากเซนเซอร์มีการรบกวนจากภายนอก รวมถึงความไม่แม่นยำของตัวเซนเซอร์เอง เราสามารถโมเดลการรบกวนเหล่านี้เป็นค่าสุ่ม ทำให้กลายเป็นปัญหา *การควบคุมเหมาะที่สุดแบบสโทแคสติก (stochastic optimal control)* ที่เป็นเนื้อหาหลักของบทนี้ ในการศึกษาจะเริ่มจากภาพรวมของปัญหาสโทแคสติก ลงสู่กรณีพิเศษเมื่อประมาณค่าพลวัตเป็นเชิงเส้นและใช้ตัวควบคุมที่เสมือนเป็นการขยายจากวิธีการที่ใช้ในระบบเชิงกำหนด

ปัญหาสโทแคสติกโดยรวมครอบคลุมเนื้อหาที่กว้างมากและเป็นพื้นฐานของการเรียนรู้เสริมกำลัง ความรู้ในบทนี้เป็นเพียงฐานเพื่อต่อยอดไปยังแนวทางตามที่ต้องการ

8.1 ปัญหาการควบคุมแบบสโทแคสติก

ในการควบคุมก่อนหน้านี้เราสมมุติว่าทราบสถานะของระบบโดยสมบูรณ์ (ค่าผิดพลาดจากการโมเดลเป็นแบบเชิงกำหนด) คำถามที่สอดคล้องกับความจริงในทางปฏิบัติคือ จะเกิดอะไรขึ้นหากค่าที่วัดได้มีการรบกวนแบบสุ่ม (random noise)? โดยทั่วไปแล้วเราอาจไม่สามารถวัดค่าสถานะทั้งหมดได้ ดังนั้นนิยามค่าจากการวัด y เป็นฟังก์ชันของสถานะ x และการรบกวน v

$$y = g(x, v) \tag{8.1}$$

กล่าวคือในระบบเชิงกำหนดเราทราบสถานะ x อย่างถูกต้องสมบูรณ์และใช้ในตัวควบคุมป้อนกลับ แต่สำหรับระบบสโทแคสติก เราทราบเพียงค่าจากการวัด y ดังนั้นต้องใช้ฟังก์ชันความหนาแน่น (density function) $p(x|y)$ คือความน่าจะเป็นในการประมาณค่า x เมื่อกำหนดค่า y

หมายเหตุ : ศัพท์ที่ใช้เรียก y คือ POMDP ย่อมาจากกระบวนการตัดสินใจมาร์คอฟที่สังเกตได้บางส่วน (Partially-Observed Markov Decision Process)

นิยามปัญหาการควบคุมเหมาะที่สุดแบบสโทแคสติกได้ดังนี้

$$\min_{u} E[J(x, u)] \tag{8.2}$$

โดย $E[.]$ แทนค่าคาดหมาย (expected value) แม้ว่าโดยหลักการแล้วเราสามารถแก้ปัญหาสโทแคสติกได้โดยใช้เครื่องมือเช่น DP หลังจากที่ครอบโดย $E[.]$ แล้วก็ตาม แต่ในกรณีทั่วไปปัญหาจะยากขึ้นมากจากฟังก์ชันความหนาแน่น ยกเว้นในกรณีที่เป็นแบบเกาส์เซียน เพราะสามารถแยกพารามิเตอร์เป็นเวกเตอร์ของค่าเฉลี่ยและเมทริกซ์ความแปรปรวนร่วมเกี่ยว (covariance)

8.1.1 ตัวควบคุมกำลังสองเชิงเส้นแบบเกาส์เซียน

พลวัตเชิงเส้นประกอบด้วยสมการสถานะและเอาต์พุตดังนี้

$$\begin{aligned} x_{k+1} &= Ax_k + Bu_k + w_k \\ y_k &= Cx_k + v_k \end{aligned} \tag{8.3}$$

สิ่งที่เพิ่มเข้ามาคือการรบกวนกระบวนการ (process noise) w_k และการรบกวนจากการวัด (measurement noise) v_k สำหรับปัญหา LQG จะตั้งสมมุติฐานว่าการรบกวนทั้งหมดเป็นแบบเกาส์เซียน $w_k \sim N(0, W),\ v_k \sim N(0, V)$ เครื่องหมาย $\sim$ หมายความว่าตัวอย่างทางด้านซ้ายถูกสุ่มจากฟังก์ชันการแจกแจงทางด้านขวา โดย $N(\mu, \Phi)$ แทนการแจกแจงแบบปรกติ (normal distribution) มีค่าเฉลี่ย μ และเมทริกซ์ความแปรปรวนร่วมเกี่ยว Φ ฟังก์ชันความหนาแน่นความน่าจะเป็นแบบเกาส์เซียน n ตัวแปรเขียนได้ดังนี้

$$p(x) = \frac{1}{\sqrt{(2\pi)^n det(S)}} exp(-\frac{1}{2}(x-\mu)^T S^{-1}(x-\mu)) \tag{8.4}$$

โดยมีค่าเฉลี่ย

$$\mu = \hat{x} = E[x] \in \mathbb{R}^n \tag{8.5}$$

และเมทริกซ์ความแปรปรวนร่วมเกี่ยว

$$S = E[(x-\mu)(x-\mu)^T] \in \mathbf{S}^n_{++} \tag{8.6}$$

สัญกรณ์ $\mathbf{S}^n_{++}$ แทนเซตของเมทริกซ์สมมาตรที่เป็นบวกแน่นอนขนาด $n \times n$

ค่าคาดหมายของฟังก์ชัน $f(x)$ นิยามได้ดังนี้

$$E[f(x)] = \int f(x)p(x)dx \tag{8.7}$$

โดยปริพันธ์ครอบคลุมปริภูมิทั้งหมด

เรากำหนดค่าเฉลี่ยเป็นศูนย์สำหรับการรบกวนโดยไม่เสียความเป็นทั่วไป เพราะหากไม่เป็นศูนย์มีวิธีที่จะประมาณค่าเฉลี่ยและหักลบออกได้ นอกจากนั้นยังตั้งสมมุติฐานว่าการรบกวนเป็นแบบ i.i.d (independently and identically distributed) หมายความว่าค่าสุ่มเป็นอิสระจากสถานะและตัวควบคุม

หมายเหตุ : ในทางปฏิบัติอาจมีกรณีที่ทำให้สมมุติฐาน i.i.d ไม่เป็นจริง ตัวอย่างเช่นโดรนอาจได้รับสัญญาณรบกวนมากขึ้นเมื่อบินใกล้ตัวกำเนิดสนามแม่เหล็กไฟฟ้าเช่นหม้อแปลงขนาดใหญ่ แต่โดยทั่วไปผลกระทบจะน้อยจนสามารถละทิ้งได้

ฟังก์ชันมูลค่า

กำหนดฟังก์ชันมูลค่าของปัญหา LQG ได้คล้ายกับ LQR เพียงครอบทั้งหมดด้วยค่าคาดหมาย

$$J = E\left[\frac{1}{2}x_N^T Q_N x_N + \frac{1}{2}\sum_{k=1}^{N-1}(x_k^T Q x_k + u_k^T R u_k)\right] \tag{8.8}$$

ใช้การเรียกซ้ำ DP เช่นเดียวกับกรณี LQR เริ่มจากขั้นเวลาปลาย N คำนวณมูลค่าของหนึ่งขั้นก่อนหน้าคือ $N-1$

$$\begin{aligned}
V_N(x) =& \frac{1}{2}E\left[x_N^T Q_N x_N\right] = \frac{1}{2}E\left[x_N^T P_N x_N\right] \\
V_{N-1}(x) =& \min_u E\left[\frac{1}{2}x_{N-1}^T Q x_{N-1} + \frac{1}{2}u^T R u\right. \\
& \left. + \frac{1}{2}(Ax_{N-1} + Bu + w_{N-1})^T P_N (Ax_{N-1} + Bu + w_{N-1})\right]
\end{aligned}$$

กระจายพจน์สุดท้ายและจัดเรียงใหม่เพื่อแยกพจน์ที่มีและไม่มีการรบกวนออกจากกัน (เนื่องจาก $E[.]$ คือการดำเนินการเชิงเส้น ดังนั้นเราสามารถดึงพจน์เข้าหรือออกได้)

$$V_{N-1}(x) = \min_u E\left[\frac{1}{2}x_{N-1}^T Q x_{N-1} + \frac{1}{2}u^T R u + (Ax_{N-1} + Bu)^T P_N (Ax_{N-1} + Bu)\right]$$
$$+ E\left[(Ax_{N-1} + Bu)^T P_N w_{N-1} + w_{N-1}^T P_N (Ax_{N-1} + Bu) + w_{N-1}^T P_N w_{N-1}\right] \quad (8.9)$$

สังเกตว่าบรรทัดบนของ (8.9) เหมือนกับ LQR มาตรฐาน สำหรับสามพจน์ที่มีการรบกวนในบรรทัดล่าง พจน์ที่หนึ่งและสองที่เป็นสหสัมพันธ์ข้าม (cross correlation) ระหว่างการรบกวนกับสถานะ/ตัวควบคุมจะมีค่าเป็นศูนย์ ทั้งนี้เพราะ ณ ขั้นเวลา k สถานะ x_k หรือตัวควบคุม u_k ไม่มีความสัมพันธ์กับ w_k (หรืออาจพิจารณาว่าถ้าดึงค่าที่ไม่เกี่ยวข้องกับการรบกวนออก จะเหลือพจน์ $E[w_{N-1}]$ ซึ่งมีค่าเฉลี่ยเป็นศูนย์) ส่วนพจน์ที่สามจะเป็นค่าคงที่

สรุปจาก (8.9) ได้ว่าพจน์การรบกวนไม่มีผลกับการคำนวณหาคำตอบตัวควบคุมเหมาะที่สุด เพราะเป็นเพียงทำให้ฟังก์ชันมูลค่าสูงขึ้นเท่านั้น

จากการอนุพัทธ์นี้ได้เป็นสองหลักการที่สำคัญด้านทฤษฎีระบบควบคุม คือ

หลักการการสมมูลของความแน่นอน (certainty-equivalence principle)

ตัวควบคุมเหมาะที่สุดสำหรับปัญหาสโทแคสติก LQG มีโครงสร้างเดียวกับตัวควบคุมเหมาะที่สุดสำหรับปัญหาเชิงกำหนด LQR เพียงแต่แทนที่สถานะ x ด้วยค่าคาดหมาย $E[x]$

หลักการการแบ่งแยก (separation principle)

สำหรับตัวควบคุม LQG เราสามารถออกแบบตัวควบคุมป้อนกลับเหมาะที่สุดและตัวประมาณค่าสถานะเหมาะที่สุดแยกกันได้ หลังจากนั้นจึงใช้งานร่วมกัน นโยบายป้อนกลับที่ได้จะเหมาะที่สุด

แม้ว่าสองหลักการนี้ไม่เป็นจริงในกรณีทั่วไป แต่ในทางปฏิบัติถูกใช้อยู่เสมอในการออกแบบนโยบายควบคุมเหมาะที่สุดรองลงมา (sub-optimal)

8.1.2 การประมาณค่าสถานะเหมาะที่สุด

จากปัญหาการควบคุมแบบสโทแคสติก ตามสมการ (8.1) เราทราบเพียงค่าจากการวัด y ที่รวมการรบกวน ต้องการประมาณค่าสถานะ $\hat{x}$ ที่เป็นตัวแทนเหมาะที่สุดของสถานะจริง x โดยใช้ *ตัวประมาณค่าสถานะ (state estimator)* ซึ่งสามารถสร้างขึ้นได้โดยวิธีการเช่น การวางโพล (pole placement) โดยอาศัยหลักการการแบ่งแยกและนำมาใช้กับตัวควบคุมป้อนกลับสถานะที่ออกแบบแยกกัน ตัวประมาณค่าสถานะโดยทั่วไปอาจเรียกว่า ตัวสังเกต (observer) หรือ Luenberger observer ตามผู้ให้กำเนิดคือ David G. Luenberger [3] แต่ในปัญหา LQG เราต้องการหาตัวประมาณค่าสถานะเหมาะที่สุด

รูปที่ 8.1 แสดง 2 วิธีในการหาค่าสถานะเหมาะที่สุดจากฟังก์ชันการแจกแจงความน่าจะเป็น

1. Maximum a-posteriori (MAP) : $argmax\ p(x|y)$ โดย $p(x|y)$ คือความน่าจะเป็นของสถานะ x เมื่อกำหนดค่าจากการวัด y
2. Minimum mean-squared error (MMSE) : $\underset{\hat{x}}{argmin}\ E[(x-\hat{x})^T(x-\hat{x})]$

โดยในกรณีฟังก์ชันแจกแจงทั่วไป (a) MAP และ MMSE จะให้ค่าที่แตกต่างกัน ซึ่งต้องพิจารณาเลือกวิธีที่เหมาะสมสำหรับปัญหา แต่สำหรับฟังก์ชันการแจกแจงแบบเกาส์เซียน ทั้งสองวิธีจะให้ผลเหมือนกัน ดังนั้นจะเลือกวิธี MMSE ที่เรียกอย่างอื่นได้ว่า วิธีกำลังสองน้อยสุด (least square) หรือ วิธีความแปรปรวนต่ำสุด (minimum variance)

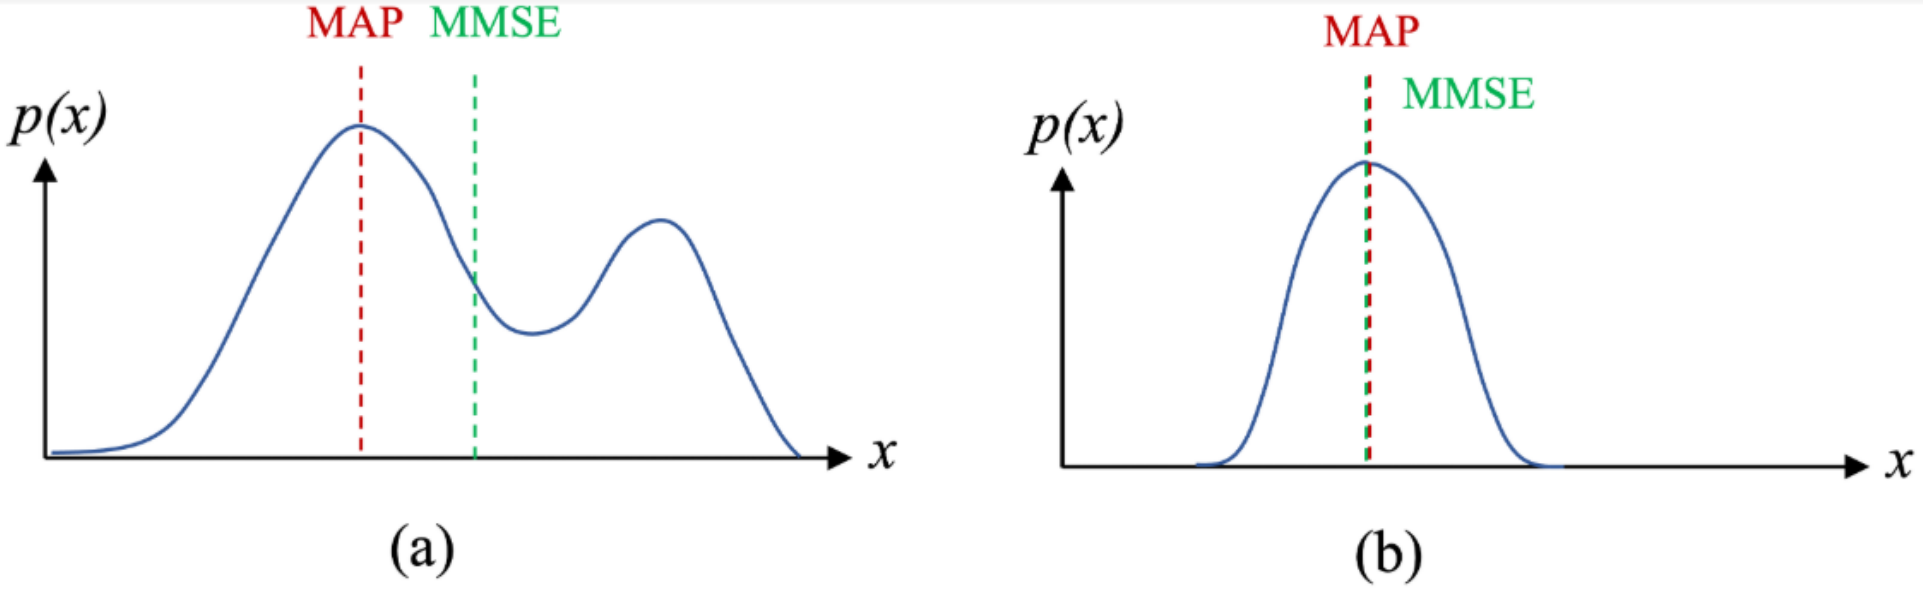

รูปที่ 8.1 การหาค่าเหมาะที่สุดจากฟังก์ชันแจกแจงความน่าจะเป็น

กลเม็ดที่จะใช้ในการอนุพัทธ์ต่อไปคือ เมื่อพิจารณา $E[(x-\hat{x})^T(x-\hat{x})]$ เป็นจำนวนสเกลาร์ ดังนั้นดำเนินการดังนี้

1. เพิ่มฟังก์ชัน $tr()$ คือรอย (trace) ได้โดยค่าไม่เปลี่ยนแปลง
2. ใช้หลักการ $tr(x^Tx) = tr(xx^T)$
3. สลับตำแหน่งระหว่าง $E[.]$ กับ $tr()$

$$
\begin{aligned}
E[(x-\hat{x})^T(x-\hat{x})] &= E[tr((x-\hat{x})^T(x-\hat{x}))] \\
&= E[tr((x-\hat{x})(x-\hat{x})^T)] \\
&= tr(E[(x-\hat{x})(x-\hat{x})^T]) \\
&= tr(\Sigma)
\end{aligned} \tag{8.10}
$$

ผลที่ได้คือรอยของเมทริกซ์ความแปรปรวนร่วมเกี่ยว

8.1.3 ตัวกรองคาลมาน

ตัวประมาณค่าเหมาะที่สุดที่ใช้ในปัญหา LQG จะรู้จักกันดีในชื่อ *ตัวกรองคาลมาน (Kalman filter)* ตามชื่อของ R.E. Kalman [4] ผู้เริ่มต้นระบบควบคุมสมัยใหม่ที่ใช้การบรรยายปริภูมิสถานะ เพื่อความกระชับต่อไปจะเรียกตัวกรองคาลมานโดยย่อว่า KF

การอนุพัทธ์ตัวกรองคาลมานทำได้หลายวิธี เช่นวิธีทางเรขาคณิตที่ใช้ในบทความ [4]ในหัวข้อนี้จะใช้วิธี MMSE เชิงเส้นแบบเวียนเกิด (recursive) คือปรับค่าของการประมาณค่าทุกขั้นเวลา แตกต่างจากวิธีแบบกลุ่ม (batch) ที่ประมวลผลข้อมูลทั้งหมดในครั้งเดียวแบบออฟไลน์

แนวคิดของวิธีนี้คือ สมมุติการประมาณค่าของสถานะปัจจุบัน ณ ขั้นเวลา k ที่รวมข้อมูลจากการวัดทั้งหมดจนถึงขั้นเวลาปัจจุบัน

$$\hat{x}_{k|k} = E\left[x_k | y_{1:k}\right] \tag{8.11}$$

และสมมุติว่าเราทราบความแปรปรวนร่วมเกี่ยวของค่าผิดพลาด

$$\Sigma_{k|k} = E\left[(x_k - \hat{x}_{k|k})(x_k - \hat{x}_{k|k})^T\right] \tag{8.12}$$

เราต้องการปรับค่า $\hat{x}$ และ Σ เมื่อมีค่าวัดใหม่ที่ขั้นเวลา t_{k+1} สามารถแยก KF ออกเป็น 2 ขั้นดังนี้

1. <u>ขั้นการทำนาย (prediction)</u>

ในขั้นนี้แนวคิดคือใช้โมเดลพลวัตเพื่อแผ่การแจกแจง 1 ขั้น โดยไม่มีค่าจากการวัด ดังนั้นทั้งหมดขึ้นกับค่าการวัดในขั้นก่อนหน้า

$$\begin{aligned}\hat{x}_{k+1|k} &= E\left[Ax_k + Bu_k + w_k | y_{1:k}\right] \\ &= A\hat{x}_{k|k} + Bu_k \end{aligned} \tag{8.13}$$

บรรทัดที่สองได้จาก u_k ไม่ใช่ค่าสุ่ม และ w_k เป็นค่าสุ่มแบบเกาส์เซียนมีค่าเฉลี่ยเป็นศูนย์ (8.13) คือการทำนายสถานะ ต่อมาคือการทำนายความแปรปรวนร่วมเกี่ยว

$$\begin{aligned}\Sigma_{k+1|k} &= E\left[(x_{k+1} - \hat{x}_{k+1|k})(x_{k+1} - \hat{x}_{k+1|k})^T\right] \\ &= E\left[(Ax_k + Bu_k + w_n - A\hat{x}_{k|k} - Bu_k)(Ax_k + Bu_k + w_n - A\hat{x}_{k|k} - Bu_k)^T\right] \\ &= AE\left[(x_k - \hat{x}_{k|k})(x_k - \hat{x}_{k|k})^T\right]A^T + E\left[w_k w_k^T\right] \\ &= A\Sigma_{k|k}A^T + W \end{aligned} \tag{8.14}$$

อธิบายรายละเอียดการอนุพัทธ์ ในบรรทัดที่สองเมื่อแทนค่าพลวัต จะเห็นว่า พจน์ Bu_k หักล้างกัน บรรทัดที่ 3 เมื่อคูณพจน์เข้าด้วยกันและใช้หลักความจริงว่า x_k และ w_k ไม่สัมพันธ์กัน (uncorrelated) ดังนั้นพจน์ที่เป็นสหสัมพันธ์ข้ามเป็นศูนย์ แยกพจน์การรบกวน w_k ออกและดึงเมทริกซ์ A และ A^T ออกจาก $E[.]$ จะได้เป็นเมทริกซ์ความแปรปรวนร่วมเกี่ยวในบรรทัดที่ 4 โดย $W \triangleq E\left[w_k w_k^T\right]$

2. <u>ขั้นปรับค่าการวัด (measurement update)</u>

ในขั้นที่สอง นิยาม *อินโนเวชัน (innovation)* เป็นความแตกต่างระหว่างค่าวัดจริงกับค่าวัดจากการทำนาย

$$\begin{aligned} z_{k+1} &= y_{k+1} - C\hat{x}_{k+1|k} \\ &= Cx_{k+1} + v_{k+1} - C\hat{x}_{k+1|k} \end{aligned} \tag{8.15}$$

คำนวณความแปรปรวนร่วมเกี่ยวของอินโนเวชันได้เป็น

$$\begin{aligned} S_{k+1} &= E\left[z_{k+1}z_{k+1}^T\right] \\ &= E\left[(Cx_{k+1} + v_{k+1} - C\hat{x}_{k+1|k})(Cx_{k+1} + v_{k+1} - C\hat{x}_{k+1|k})^T\right] \end{aligned} \tag{8.16}$$

เมื่อใช้หลักการพจน์สหสัมพันธ์ข้ามเป็นศูนย์เนื่องจาก v_{k+1} และ x_{k+1} ไม่สัมพันธ์กัน

$$\begin{aligned} S_{k+1} &= CE\left[(x_{k+1} - \hat{x}_{k+1|k})(x_{k+1} - \hat{x}_{k+1|k})^T\right]C^T + E\left[v_{k+1}v_{k+1}^T\right] \\ &= C\Sigma_{k+1|k}C^T + V \end{aligned} \tag{8.17}$$

อินโนเวชันเป็นศัพท์ทางด้านการประมวลสัญญาณที่ใช้กับการออกแบบตัวกรองทั่วไป สรุปได้ว่าเป็นค่าผิดพลาดในการทำนายที่จะป้อนกลับให้ตัวกรองคาลมานเพื่อควบคุมการประมาณค่า ดังนั้นการปรับค่าสถานะโดยใช้อินโนเวชันเขียนได้เป็นดังนี้

$$\hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + L_{k+1} z_{k+1} \tag{8.18}$$

โดย L_{k+1} เรียกว่า *อัตราขยายคาลมาน (Kalman gain)*

เพื่อบรรลุวัตถุประสงค์คือต้องการหาค่าเหมาะที่สุดสำหรับอัตราขยายคาลมาน ต้องการการปรับค่าความแปรปรวนร่วมเกี่ยว เมื่อแทนค่า (8.18) และพิจารณาพจน์สหสัมพันธ์ข้ามเป็นศูนย์เนื่องจาก v_{k+1} และ x_{k+1} ไม่สัมพันธ์กัน จะได้เป็น

$$\begin{aligned}
\Sigma_{k+1|k+1} &= E\left[(x_{k+1} - \hat{x}_{k+1})(x_{k+1} - \hat{x}_{k+1})^T\right] \\
&= E\left[(x_{k+1} - \hat{x}_{k+1|k} - L_{k+1}(Cx_{k+1} + v_{k+1} - C\hat{x}_{k+1|k}))(x_{k+1} - \hat{x}_{k+1|k} - L_{k+1}(Cx_{k+1} + v_{k+1} - C\hat{x}_{k+1|k}))^T\right] \\
&= (I - L_{k+1}C)\Sigma_{k+1|k}(I - L_{k+1}C)^T + L_{k+1}VL_{k+1}^T
\end{aligned} \tag{8.19}$$

แม้ว่าในบทความอื่นอาจมีการนำเสนอรูปแบบที่แตกต่างกันไป แต่ผลที่ได้ในบรรทัดสุดท้ายของ (8.19) เรียกว่า *รูปแบบโจเซฟ (Joseph form)* ซึ่งเป็นรูปแบบที่เหมาะสมในทางปฏิบัติ เนื่องจากมีความเป็นสมมาตรและรับประกันความเป็นบวกแน่นอน

ใช้ (8.19) ในการคำนวณหาอัตราขยายคาลมาน เราใช้วิธีหาค่า MMSE จาก (8.10)

$$
\begin{aligned}
MMSE &\Rightarrow \min_{L_{k+1}} \; E\left[(x_{k+1} - \hat{x}_{k+1|k+1})^T (x_{k+1} - \hat{x}_{k+1|k+1})\right] \\
&\Rightarrow \min_{L_{k+1}} \; tr(\Sigma_{k+1|k+1})
\end{aligned} \tag{8.20}
$$

ใช้วิธีที่ได้เคยศึกษามาก่อนหน้านี้ คือกำหนดให้

$$
\frac{\partial tr(\Sigma_{k+1|k+1})}{\partial L_{k+1}} = 0 \tag{8.21}
$$

และหาคำตอบ L_{k+1} (รายละเอียดทิ้งให้เป็นแบบฝึกหัด)

$$
L_{k+1} = \Sigma_{k+1|k} C^T S_{k+1}^{-1} \tag{8.22}
$$

สรุปโครงสร้างของอัลกอริทึมได้ดังนี้

<u>อัลกอริทึม KF</u>

1. กำหนดค่าเริ่มต้น $\hat{x}_{0|0}, \Sigma_{0|0}, W, V$

วนซ้ำขั้นตอน 2-5

2. ทำนายโดยใช้ (8.13), (8.14)

$$\hat{x}_{k+1|k} = A\hat{x}_{k|k} + Bu_k$$
$$\Sigma_{k+1|k} = A\Sigma_{k|k}A^T + W$$

3. คำนวณอินโนเวชันและความแปรปรวนร่วมเกี่ยวตาม (8.15), (8.17)

$$z_{k+1} = y_{k+1} - C\hat{x}_{k+1|k}$$
$$S_{k+1} = C\Sigma_{k+1|k}C^T + V$$

4. คำนวณอัตราขยายคาลมาน (8.22)

$$L_{k+1} = \Sigma_{k+1|k}C^T S_{k+1}^{-1}$$

5. ปรับค่าตาม (8.18), (8.19)

$$\hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + L_{k+1}z_{k+1}$$
$$\Sigma_{k+1|k+1} = (I - L_{k+1}C)\Sigma_{k+1|k}(I - L_{k+1}C)^T + L_{k+1}VL_{k+1}^T$$

ตัวอย่าง 8.1

ในตัวอย่างนี้จะแสดงการควบคุม LQG สำหรับพลวัตอย่างง่าย คือตัวปริพันธ์คู่ที่ใช้ในตัวอย่าง LQR ในบทที่ 3 เริ่มโดยการนิยามฟังก์ชันและกำหนดเมทริกซ์ A, B, C สำหรับพลวัต ตัวแปรกำหนดจำนวนสถานะ ตัวควบคุม จำนวนขั้นเวลาที่ขึ้นกับเวลาปลาย เมทริกซ์น้ำหนัก Q, R, Q_N สำหรับฟังก์ชันมูลค่า ซึ่งในส่วนนี้จะเหมือนกับในตัวอย่างบทที่ 3 ยกเว้นรายละเอียดเล็กน้อยเช่นการเพิ่มเมทริกซ์ C ตาม (8.3)

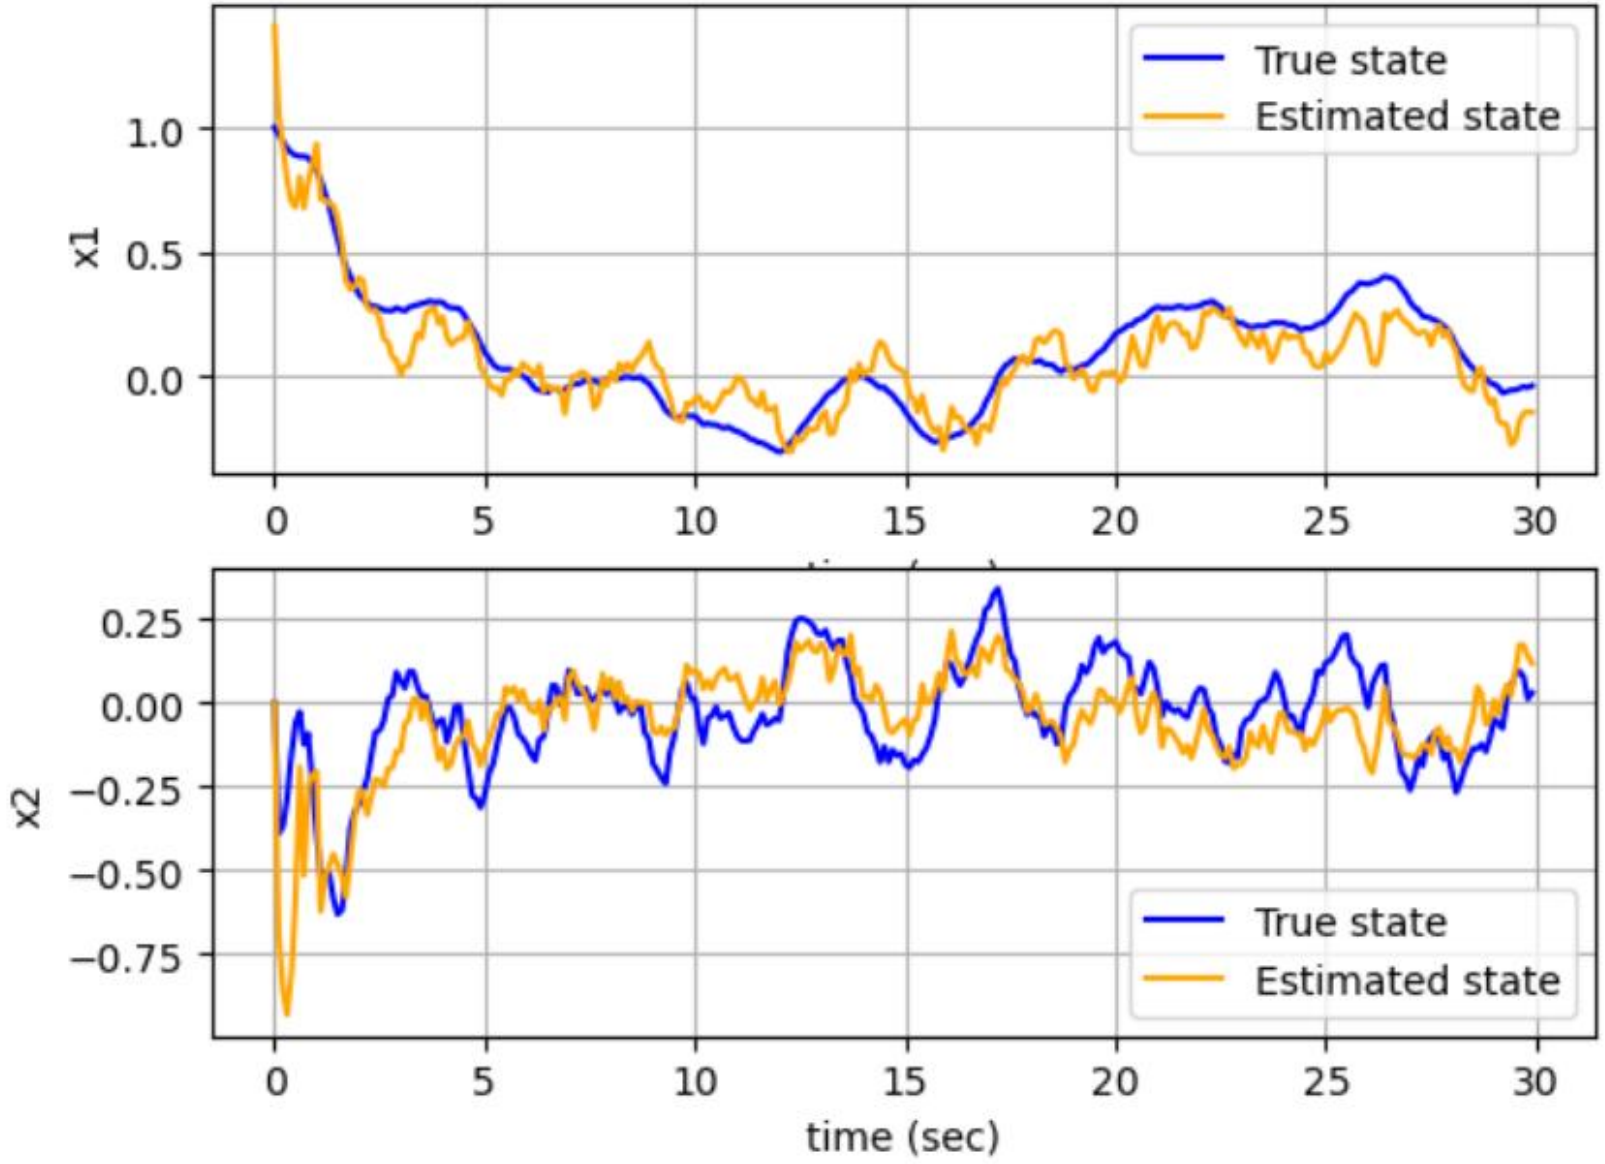

รูปที่ 8.2 เปรียบเทียบสถานะจริงกับการประมาณค่าโดย KF

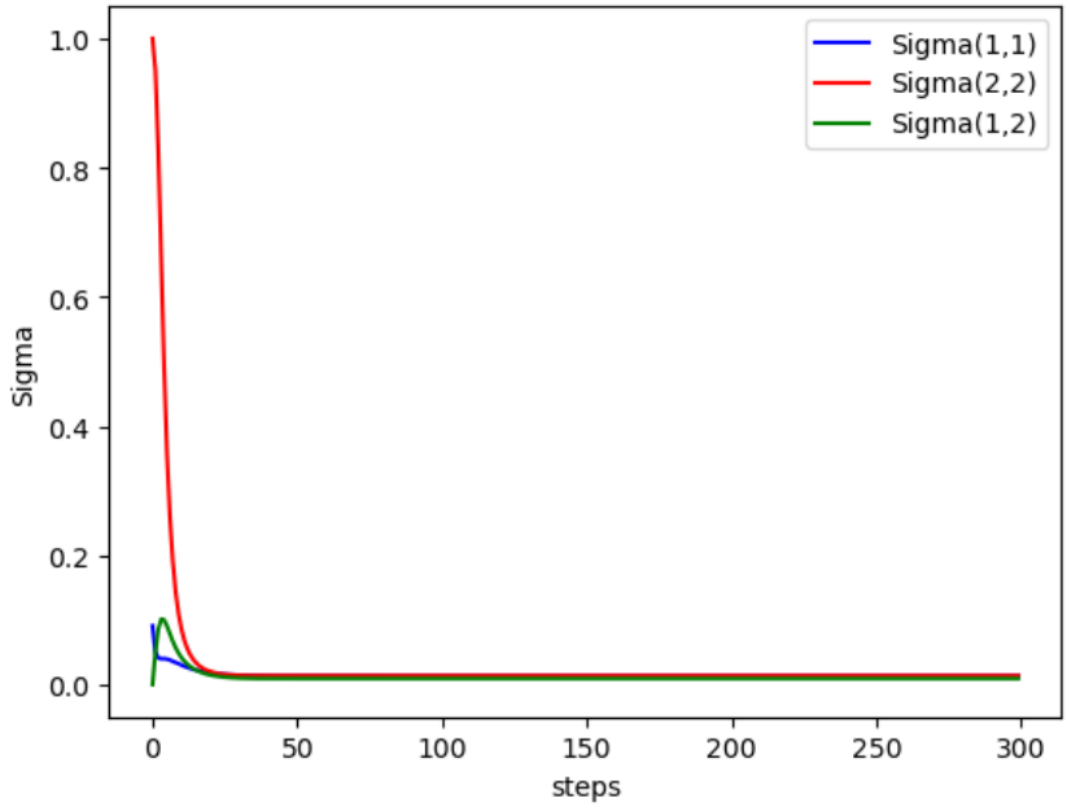

รูปที่ 8.3 การลู่เข้าของสมาชิกเมทริกซ์ความแปรปรวนร่วมเกี่ยว

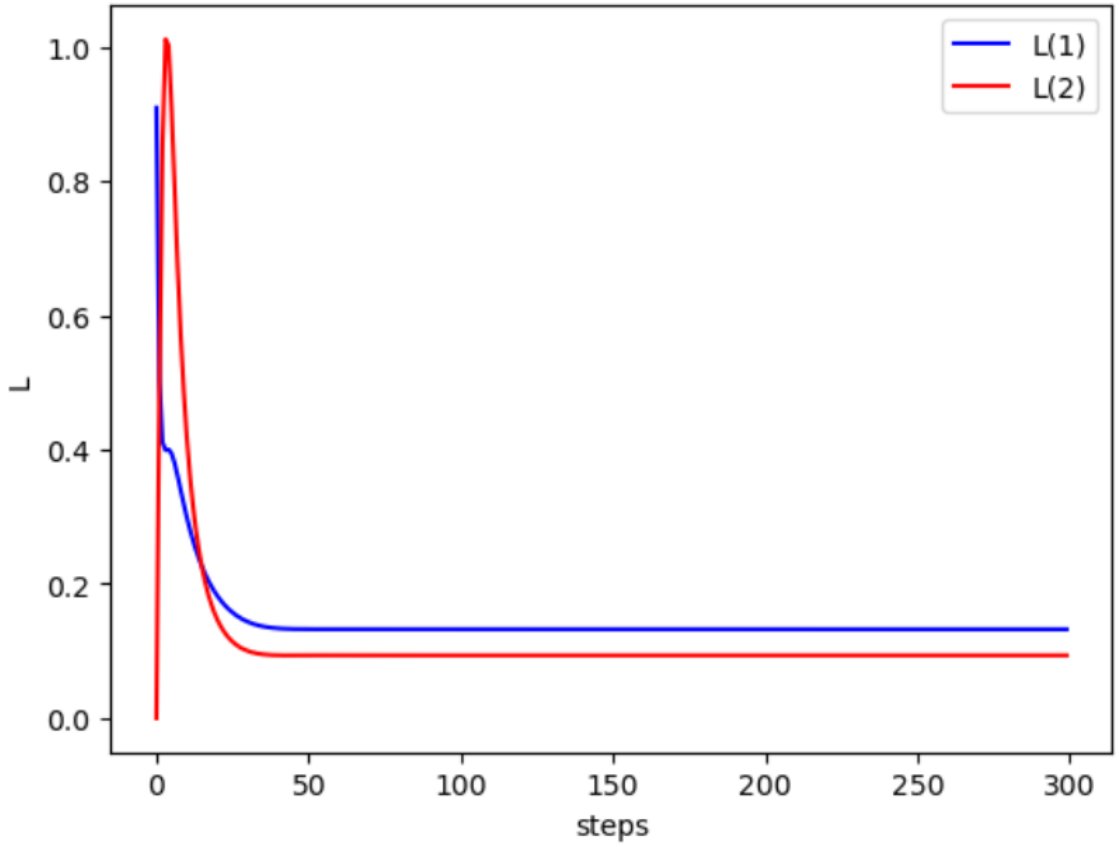

รูปที่ 8.4 การลู่เข้าของสมาชิกอัตราขยายคาลมาน

วีดีโอจาก CMU16-745 (2025)

- Lecture 19 : Stochastic Optimal Control and LQG
- Lecture 21 : Kalman Filters and Duality

วีดีโอจาก MIT 6.8210 (2024)

- Lecture 19 : Stochastic Dynamics
- Lecture 20 : Stochastic Control

บรรณานุกรม

1. Z. Manchester et.al. 16-745 Optimal Control & Reinforcement Learning, Course materials ,Carnegie Mellon University. 2025.
2. R. Tedrake. Underactuated Robotics: Algorithms for Walking, Running, Swimming, Flying, and Manipulation (Course Notes for MIT 6.832). 2023.
3. D.G. Luenberger. Determining the State of a Linear System with Observers of Low Dynamic Order. Electrical Engineering (Ph.D. thesis). Stanford University. 1963.
4. R.E. Kalman. "A new approach to linear filtering and prediction problems. Journal of Basic Engineering. 82 (1): 35–45. 1960.